

Brilliant Sort：确定性核心、Harness 与 AI Agent 验证方案

对应题目： 游戏研发基础设施 / AI Agent 方向笔试：Brilliant Sort

代码版本： 23ae899 (2026-07-16)

线上 Demo：Hong Kong · GitHub Pages

CI 证据：Actions #29492121811 (verify、publish-hk、deploy 全部成功)

摘要

本提交把 Brilliant Sort 建模为一个与 UI、动画、音频和具体引擎无关的确定性状态机。生产规则由 headless C++20 `BrilliantSortCore` 实现，并编译为浏览器 WASM；React 只经由 `GameCorePort` 消费状态转移，TypeScript reducer 仅保留为独立差分 Oracle。固定 `LevelSpec`、命令回放、canonical dump、原生/WASM 三后端差分 Harness、浏览器 E2E 与人工视觉/听觉验收共同构成可执行证据链。

题目要求的是 Demo 的核心逻辑与工程结构；仓库额外实现了可在线游玩的 Tux 旗舰关卡、确定性像素资产管线、独立 C++ AudioWorklet 合成器、双站静态部署、两级本地 Git 门禁，以及四种 Agent 可直接使用的 OpenSpec 技能。这些额外部分不改变核心论点：**规则唯一、边界可驱动、状态可序列化、失败可定位、AI 输出可验证。**

1. 玩法假设（8 行）

- 每个有效棋盘格具有目标颜色，且至多容纳一颗具有独立当前颜色的宝石。
- 宝石仅在当前颜色与目标颜色不同的时候可移动；匹配宝石永久锁定。
- 点击可移动宝石会选择同色、可移动、八方向连通的最大分量。
- 部分提取只允许移走边界上的安全成员，剩余选择分量必须继续八方向连通。
- Shelf 是一个紧凑、有序、可配置容量的序列；旗舰关卡使用 16 槽，表现为两个各 8 槽的 Bank。
- 只能把选择中的宝石放入同色且为空的目标连通分量；目标不足时保留未放置选择。
- 所有有效格均颜色匹配、选择为空且 Shelf 为空时胜利；`apply-global-wand` 按颜色、宝石 ID 和行优先目标确定性地完成同一胜利谓词。
- 本 Demo 没有失败、计时或步数状态；关卡由固定 JSON 提供，随机生成、商业 Power-up、LiveOps 和账号状态明确延期。

这些假设来自自己归档的核心、Tux 舞台、渲染和 Demo 辅助终章规格。新加的重玩按钮只调用既有 `restart-level` 命令，不改玩法规则；视频里没有出现的商业功能，也没有被擅自补成规则。

2. 核心状态与所有权


概念	表示	所有权与约束
LevelSpec	版本化 JSON：行列、有效格、目标颜色、初始宝石、Shelf 容量	固定内容源；验证唯一 Gem ID、有效 mask、颜色守恒和容量
GameState	稀疏棋盘、Gem 映射、Shelf、选择、Playing/Won	仅规则核心可以写入
BoardCell / Gem	目标颜色与宝石 ID 分离；Gem 自带颜色	使“正确锁定”和“错误可移动”成为导出谓词
Shelf	紧凑 gemIds[] 序列，带宽度与容量	移除即语义性向前压缩；两个 Bank 不会成为两个逻辑 Shelf
Selection	来源容器、不可变 anchor、颜色、有序 Gem ID 集	不是复制出来的新宝石；剩余成员必须保持连通
GameCommand	选棋盘、选 Shelf、放入目标、放入 Shelf、取消、重开	UI、Harness、Agent 都只通过命令驱动
CoreTransition	新状态、有序事件、结构化拒绝、canonical dump	每次 dispatch 产生一个完整、可断言的转移

核心接口很小：

```
interface GameCorePort {
  dispatch(command: GameCommand): CoreTransition;
  snapshot(): GameState;
  restart(): CoreTransition;
  destroy(): void;
}
```

GameCorePort 是表现层、Harness 和 Agent 的共同边界；canonicalDump 稳定排序棋盘坐标、Gem ID、Shelf 序列与选择成员，因此不会混入 DOM、对象地址、动画时间或设备状态。

3. 模块边界与运行架构



Brilliant Sort 架构图

规则核心

`cpp/game_core.*` 的 `BrilliantSortCore` 拥有关卡加载与验证、八方向连通、锁定判定、安全提取、目标放置、确定性全局修复、Shelf 压缩、拒绝、胜利和 canonical 序列化。它不拥有 DOM、CSS、PNG、ARIA、输入命中、动画时钟、音频时钟或布局。

这份禁区清单给代码审查一个很简单的判断办法：DOM 节点、动画进度或音频状态一旦出现在 `GameState` 里，职责就漂了，不必等到回放坏掉才发现。

C++ 对外只暴露窄 JSON v1 / C ABI；`src/wasm/game-core.ts` 把它封装为 `GameCorePort`。这样未来接入 Cocos 或其它游戏引擎时，只需替换表现适配器，不需要复制规则或改动回放协议。

表现、音频与规则的关系

React 根据 `CoreTransition` 渲染像素素材、无障碍语义、键盘/触摸输入、一次性提示和临时 WAAP/ SVG 动画。普通移动和魔法棒全图波次都只测量已提交状态的来源/目标矩形，弧光、固定烟花和胜利后的重玩按钮也不修改 canonical state。重玩通过 `restart-level` 回到初始状态，表现层只递增相机 reset key；新手提示和静音偏好不跟着清空。`PixelAudioEngine` 只消费 post-dispatch `AudioCue`；AudioContext 生命周期、设备采样率、静音偏好、音乐进度均不进入 `GameState` 或 replay。

重玩功能暴露了原实现里一个很具体的生命周期错误：音频引擎把 `won` 当成“整个引擎只能提交一次”，所以第二局不会再播胜利音乐。修复没有重建 AudioContext，而是在 12 字节 Cue 协议里追加 `Restart = 7`；浏览器按 `Won` → `Restart` → `Won` 投递，C++ 引擎按局重置 Voice、Score Transport、Layer 和胜利锁存，同时保留静音状态。原生诊断断言两次 fanfare，浏览器 E2E 断言实际传入 Worklet 的 kind 序列为 `[6, 7, 6]`。

TypeScript 的定位

TypeScript reducer 保留为差分 Oracle，而不是浏览器生产回退。生产浏览器经 WASM 调用 C++ 核心；如果 WASM 初始化失败，应用明确失败或音频静默降级，不会偷偷切换到另一套规则引擎。

4. 关键规则流程

4.1 选择

`SelectBoardGem(coord)` 校验有效格、宝石存在和可移动性后，以八方向邻居寻找同色最大连通分量。锁定宝石、空格与异色宝石都中断路径。遍历和返回顺序稳定，避免不同后端或同一 Agent 重放出现歧义。

4.2 安全部分提取与 Shelf

对当前选择集合 `S`，核心只接受 `Frontier(S) ∩ SafeToRemove(S)` 中的成员；`SafeToRemove` 会重新检查 `S - {v}` 的八方向连通性。候选先按到 `selection.anchor` 的 Chebyshev 距离排序，距离相同再比较行、列。放入 Shelf 时最多取 `min(selection.size, freeSlots)` 个成员；容量不够就保留剩余选择，不会悄悄丢掉宝石。

4.3 放置、全局修复、重玩、拒绝与胜利

`PlaceSelectionAtTarget(coord)` 只接受同色、有效、空的目标格。核心从点击位置找出同色空目标分量，以点击格为 anchor，按 Chebyshev 距离、行、列排序；每放一颗宝石都会重新计算安全来源，再与下一个目标配对。

`apply-global-wand` 保留已匹配锁定宝石，按颜色收集 Board/Shelf 中其余身份，再将字典序 Gem ID 配对到行优先同色空目标；它清空 Shelf/选择，只发出一个 `global-wand-applied` 和一个 `won`。终章和宝石飞行结束后，右上角重玩按钮才出现；它 dispatch 既有 `restart-level`，恢复初始 Board、空 Shelf、空选择和默认相机，不刷新页面。错误目标、满 Shelf、锁定宝石和无可选宝石都返回稳定 `Rejection`，逻辑状态不变。胜利条件仍是：Shelf 空、选择空、全部有效格有宝石且颜色匹配。

5. Harness 与自动化验收

Harness 的设计目标不是“列出测试名称”，而是让任意固定关卡在同一协议下被加载、驱动、序列化、重放、比较和诊断：

```
scenario.load(LevelSpec) → command.apply(GameCommand) → CoreTransition
    → before/after canonical dump + events + rejection
    → trace.replay(commandLog) → snapshot.diff(expected, actual)
```

三后端差分会逐命令比较 TypeScript Oracle、native C++ 和 WASM C++ 的 `canonicalDump`、events 与 rejection。发生分歧时，诊断包括 scenario、命令索引、命令 JSON、后端、前后状态、首个 JSON 路径差异、期望/实际 events 和 rejection，不把“失败”压缩成不可行动的一行文本。

必须覆盖的自动化场景

场景	初始状态与操作	预期结果	失败诊断
八方向选择	固定小棋盘，斜对角同色可动宝石，夹有锁定/异色屏障； 点击起点	仅返回同色可动八连通分量， 起点第一，稳定 BFS 顺序	起点、返回坐标、期望与实际 顺序、错误屏障路径
部分入 Shelf 与压缩	选择大于剩余容量的分量，再 从 Shelf 放回目标	仅安全成员进入 Shelf；剩余 选择连通；移除后 row-major 紧凑	Shelf 序列、剩余 component、容量、首个不 连通点
拒绝不变性	点击锁定/空格/错误颜色目标/ 满 Shelf	收到指定 <code>Rejection</code> ，状态 dump 保持字节相同	命令、rejection code、 before/after dump 的首个差 异
<code>tux-01</code> 胜利回放	24×32、546 有效格、16 槽 Shelf；回放提交的 48 条命令	三后端逐 transition 一致，最 终 <code>Won</code> 、Shelf 空、546 格匹 配	command index、 backend、前后 dump、 events、rejection、首个 JSON 路径
<code>tux-01</code> 全局修复	分别从初始状态和 Shelf 已占 用的中途状态发送 <code>apply- global-wand</code>	锁定身份不动、136 个可移动 身份守恒、Shelf/选择清空； 三后端 canonical dump 一 致，事件严格为聚合事件后接 <code>won</code>	backend、事件序列、首个 identity/location 或 canonical JSON 差异

`src/harness/differential.ts` 让这套诊断成为真实实现，而不是设计口号；`bun run harness differential tux-01` 可重放旗舰关卡的三后端证明。

6. AI Agent 的使用与验证

让 Agent 做什么

Agent 可承担限定范围内的模块拆解、接口审查、实现、测试补充、审查生成的像素资产、读取差分日志和提出修复。它不应自行发明未观察到的商业规则、随机模式或支付流程；内置魔法棒则是经规格化、三后端验证的确定性 Demo 辅助，不是商业 Power-up。

给 Agent 的上下文与可执行反馈

已归档和活动中的 OpenSpec 提供题目事实、假设、非目标、模块边界、接受标准和人工验收门。项目上下文已迁入 `openspec/config.yaml`；OpenSpec 1.6 官方生成的 `propose / apply / explore / sync / archive` 技能提交在 `.omp/`、`.codex/`、`.claude/` 和 `.opencode/`，同一套约束可以直接交给 Oh My Pi、Codex、Claude Code 与 OpenCode。`src/agent/context.ts` 会拒绝请求中包含明确延期的能力；`src/agent/audit.ts` 记录规格版本、改动文件、验证命令、结果、下一决策和时间戳。

`tests/agent/context.test.ts` 里的 `deferred capability requests stop before speculative implementation` 会把含有 `power-up` 和 `payment` 的请求交给上下文构造器，并断言结果为 `blocked`。也就是说，越界请求在生成实现方案之前就会停住。

Agent 的可执行反馈不是自然语言“看起来不对”，而是固定 fixture、命令日志、canonical dump、事件、rejection、Harness 首个 JSON 差异、原生/WASM 差分和浏览器 E2E。Lefthook 再把这些门禁放到真实开发路径上：pre-commit 并行跑类型、Bun 测试、夹具与严格规格，pre-push 顺序跑 native/WASM/生产构建和 desktop/mobile Playwright，避免共享构建目录互相打架。

一个容易误解的边界与发现方式

规则误解：两个视觉 Shelf Bank 很容易诱导 Agent 实现成两个独立逻辑容器。规格明确规定核心仅有一个紧凑 `Shelf.gemIds` 序列，A/B 只是在表现层按索引 `0..7` 与 `8..15` 切片；否则追加顺序、部分提取和压缩都会产生错误。固定 Shelf 回放和 canonical dump 会立即暴露这种偏差。

表现误解（实际修复案例）：初版飞行克隆只平移，Large Shelf 宝石抵达 Micro 棋盘格时会突然换图。规则差分不会发现该问题；浏览器中帧和 E2E 则要求来源/终点矩形对齐、一个可见表示、双向 `translate + scale`、Large/Micro 离散 LOD 交接和动画结束后才解锁输入。该修复说明“逻辑测试通过”不等于“产品表现合格”。

7. C++ 小型代码题

题目要求的 `FindConnectedMovableGems` 位于：`cpp/connected_gems.hpp` 与 `cpp/connected_gems.cpp`。它采用 BFS，稳定邻居次序为 N, NE, E, SE, S, SW, W, NW：

```
std::vector<std::pair<int, int>> FindConnectedMovableGems(
    const std::vector<std::vector<GemCell>>& board,
    int startRow,
    int startCol);
```

- 越界、空宝石或不可动起点返回空。
- 入队时标记 visited，确保不重复返回。
- 仅扩展与起点同色且可动的八方向邻居。
- 返回顺序是起点在前的 BFS 发现顺序。
- 对已发现网格的时间与辅助空间复杂度均为 $O(V)$ 。

下面两个 3×3 例子把输入和返回顺序直接列出来。`R` 表示颜色为 1 且可移动的宝石，`.` 表示空格。

例 1: start = (0, 0)

R . .
. R .
. . R

返回 [(0,0),(1,1),(2,2)]

例 2: start = (1, 1)

. R .
. R R
. . R

返回 [(1,1),(0,1),(1,2),(2,2)]

`cpp/connected_gems_test.cpp` 还覆盖锁定/异色屏障、无效起点和输入不变性。

如果把这个函数扩展成“放置优先级”，目标颜色先筛出可用目标，Shelf 剩余容量或目标数量决定本轮最多移动几颗。来源取 `Frontier(S) ∩ SafeToRemove(S)`，目标取点击位置所在的同色空分量；两边都按 anchor 的

Chebyshev 距离、行、列排序，然后依次配对。每移动一颗都要重新计算安全来源；来源在 Shelf 时，还要按压缩后的坐标复查剩余选择是否连通。这样拓扑搜索只回答“哪些格连着”，放置规则负责“先搬谁、放哪里”。

8. 扩展边界

易于扩展	需要协议升级或重构
新固定关卡、颜色、像素素材、音效/音乐、Harness 场景；全后端同步的加法型确定性命令	破坏现有命令形状、多个逻辑 Shelf、失败/计时状态、商业 Power-up 改变占用规则
新 React/Cocos 表现适配器、更多无障碍展示、纯表现动画	运行时随机生成进入 replay、持久化档案/货币、联机或非确定性物理
新的 fixture 验证器与赢局 trace	LevelSpec 语义版本变更、JSON ABI 破坏性改动、跨平台协议迁移

这一区分避免把“可换表现层”误当作“任何规则都可零成本加进去”。新增规则必须同步更新核心规格、夹具验证器、replay 基线、Harness 断言、C++/WASM 协议和 Agent 约束。

9. 复现与证据

```
bun install --frozen-lockfile
bun run hooks:install
bunx lefthook run pre-commit --all-files
bunx lefthook run pre-push --all-files
bun run check
bun run test:e2e
bun run harness replay tux-01
bun run harness differential tux-01
bun run level:check:tux
```

作为复现成本参考，GitHub Actions run #29492121811 的 verify 在 Ubuntu runner 上用时 1 分 58 秒，其中包括安装固定版本的 Emscripten 和 Chromium、编译三个后端并运行全部自动化检查。本地已有依赖和浏览器缓存时通常更快；第一次运行主要看下载速度。

在本答卷工作站上，四项并行 pre-commit 门禁用时 1.27 秒，完整 pre-push 门禁用时 20.91 秒；这是实测值，不是对其它机器的固定承诺。

对应版本的本地验证包括 35 个 Bun 测试、4 个 native CTest（含固定 48 kHz PCM 哈希和两局 fanfare 诊断）、22 次 desktop/mobile Chromium E2E，以及 48 命令 Tux 与初始/中途魔法棒场景的三后端逐 transition parity。浏览器回归还覆盖 Won → Restart → Won 音频 Cue、重玩时机、键盘操作、canonical 重开、相机复位、偏好保留、移动布局和 reduced motion。CI 在 Ubuntu 上重新执行类型检查、native C++、WASM 构建、Bun 测试、CTest、Chromium E2E、Hong Kong 静态产物和 GitHub Pages 部署。

详细的“题目要求 → 设计 → 代码 → 测试/线上证据”索引见：submission/evidence-matrix.md。OpenSpec 是需求来源和验收记录，不是事后补写的故事；以下功能均已完成自动验证与人工产品验收并归档：

- 2026-07-15-add-brilliant-sort-core
- 2026-07-16-add-pixel-crystal-renderer
- 2026-07-16-rebuild-tux-mosaic-stage
- 2026-07-16-add-cpp-pixel-audio-engine
- 2026-07-16-add-demo-assist-and-victory-finale
- 2026-07-16-add-win-replay-control

结论

该方案的交付重点不是一张可玩的截图，而是把复杂度收敛到可验证边界：一个可替换表现层的规则核心、一套可重放/可比较/可诊断的状态协议、一条能约束 AI 输出的验收闭环，以及可独立编译验证的 C++ 连通算法。在线 Tux Demo、像素资产和确定性音频证明这些边界能够承载真实产品表现，但它们不替代核心工程证据。